DETEKSI TUMOR OTAK PADA CITRA *MAGNETIC RESONANCE IMAGING* (MRI) MENGGUNAKAN *YOU ONLY LOOK ONCE VERSI 5* (YOLOv5)

Azzahra Raihani Putri*, Endah Purwanti, S.Si., M.T., Winarno, S.Si., M.T.

Teknik Biomedis, Fakultas Sains dan Teknologi, Universitas Airlangga, Indonesia

*Email Koresponden Penulis: azzahra.raihani.putri-2019@fst.unair.ac.id

ABSTRAK

Tumor otak merupakan massa jaringan abnormal yang berkembang serta tumbuh pada sel-sel otak. Kasus tumor otak yang sering terjadi di Indonesia adalah glioma, meningioma, dan *pituitary tumor* yang masing-masingnya memiliki lokasi dan karakteristik yang berbeda. Pada proses pemeriksaan radiologi untuk mendeteksi tumor otak dilakukan dengan pengamatan secara manual pada citra MRI otak pasien yang dapat memakan waktu dan sangat bergantung kepada kemampuan dan pengalaman tenaga ahli. Banyak penelitian tentang *deep learning* yang telah menunjukkan performa tinggi pada model dalam mengklasifikasi citra MRI. Namun, terdapat sebagian studi klasifikasi dengan masalah kualitas citra dan ketidakseimbangan kelas memberikan performa yang buruk pada model. Penelitian ini bertujuan untuk menerapkan salah satu model *deep learning*, yaitu YOLOv5 untuk mendeteksi citra MRI glioma, meningioma, dan *pituitary tumor* pada kelas yang tidak seimbang. Proses deteksi dilakukan pada dataset citra MRI yang diterapkan variasi *image enhancement*, yaitu filter gaussian, filter median, CLAHE, CLAHE+filter gaussian, dan CLAHE+filter median. Lalu menerapkan metode *balancing data*, yaitu SMOTE pada setiap dataset untuk mengatasi permasalahan ketidakseimbangan kelas. Hasil penelitian ini menunjukkan bahwa dapat memberikan performa yang baik dan dapat meningkatkan nilai rata-rata akurasi sebesar 0.05 dari dataset asli senilai 0,917 menjadi 0,963 dari dataset SMOTE. Rancangan model YOLOv5 terbaik yang diperoleh adalah CLAHE 9x9+filter median radius 3 pada dataset SMOTE dengan nilai rata-rata *F1-score* sebesar 0,935 dengan akurasi 0,964.

Kata Kunci: *Tumor otak, YOLOv5, Image enhancement, Balancing data,*

1. PENDAHULUAN

Tumor otak terjadi disebabkan adanya massa jaringan abnormal yang berkembang serta tumbuh pada sel - sel otak. Berdasarkan asalnya, tumor otak dapat diklasifikasi menjadi 2 tipe, yaitu tumor otak primer (tumor yang berasal dari jaringan otak atau area dekat otak) dan tumor otak metastatik (tumor yang berasal dari organ badan yang lain berkembang hingga ke otak) (Ghozali et al., 2021). Berdasarkan data statistik *Global Cancer* pada tahun 2020, jumlah insiden tumor otak adalah 308.102 dengan jumlah kematian 251.329 (81,57%) di dunia. Pada Asia Tenggara, jumlah insiden tumor otak adalah 16.643 dengan jumlah kematian 14.631 (87.91%) dan Indonesia menjadi negara tertinggi di Asia Tenggara dengan jumlah kejadian 5.964 dan jumlah kematian 5.298 (88,83%) (GLOBOCAN, 2020). Menurut hasil penelitian dari Wahyuhadi et al., jenis tumor otak yang sering terjadi di Indonesia adalah meningioma (36,9%), glioma (35,9%), dan *pituitary tumor* (12,7%) (Wahyuhadi et al., 2021).

Meningioma merupakan tumor otak primer yang berasal dari meninges yang mengelilingi otak dan sumsum tulang belakang. Jenis meningioma paling umum adalah tumor jinak dan sebagian kecil terdapat tumor ganas (Moreau et al., 2020). *Pituitary tumor* merupakan tumor otak primer yang tumbuh pada kelenjar pituitari. Sebagian besar tumor jenis ini jinak tetapi dapat membahayakan saat bertumbuh cukup besar, karena dapat menekan struktur di dekatnya atau dapat mengganggu produksi hormon yang menyebabkan produksi hormon terlalu banyak atau terlalu sedikit (Chin, 2020). Glioma merupakan tumor otak primer yang bermula di sel glial dan umumnya merupakan tumor otak ganas. Sekitar 78% dari tumor otak ganas adalah glioma (Ghozali et al., 2021). Berdasarkan jenis tumor otak serta lokasi pertumbuhannya yang bervariasi, diperlukan diagnosis yang akurat untuk membantu mempercepat penentuan pengobatan yang akan diberikan dengan tepat, sehingga dapat menekan pertumbuhan dan perkembangan tumor.

Diagnosis tumor otak dapat ditentukan dari anamnesis, tes darah, pemeriksaan penunjang radiologi, hingga teknik biopsi. Salah satu pemeriksaan radiologi yang baik dalam mendeteksi tumor otak adalah *Magnetic Resonance Imaging* (MRI) (Maulida et al., 2019). MRI dapat memperlihatkan citra jaringan lunak dalam otak dan mampu menampilkan perkembangan penyakit serta lesi aktif, namun memiliki keterbatasan dalam menilai klasifikasi. Proses klasifikasi tumor otak dilakukan dengan pengamatan langsung secara manual pada citra hasil MRI otak pasien yang dapat memakan waktu cukup lama dan sangat bergantung kepada kemampuan dan pengalaman tenaga ahli dalam menganalisis (Li et al., 2018). Dalam mengatasi permasalahan tersebut, maka dibutuhkan suatu metode alternatif dengan menggunakan model yang dapat mendeteksi, mengklasifikasi, serta melokalisasi jenis-jenis tumor otak secara otomatis. Solusi dari masalah tersebut dapat menggunakan *Deep Learning* (DL).

Deep Learning (DL) digunakan dengan tujuan untuk mempermudah, mempercepat, dan meningkatkan akurasi proses deteksi dan klasifikasi jenis tumor otak, seperti glioma, meningioma, dan tumor pituitari. Salah satu penelitian yang menggunakan DL dilakukan oleh Brindha et al. untuk mendeteksi dan klasifikasi citra otak normal dengan otak yang terdapat tumor menggunakan *Artificial Neural Network* (ANN) dan *Convolutional Neural Network* (CNN) yang menghasilkan nilai akurasi CNN (89%), sedangkan ANN (65,21%).. Namun terdapat kelemahan dari penelitian ini, yaitu akurasi yang rendah, tidak dapat melakukan lokalisasi daerah tumor pada otak, dan data yang digunakan terbatas dan kurang bervariasi karena data hanya citra otak normal dengan citra otak terdapat tumor tanpa diketahui jenis tumor otak secara spesifik, sehingga algoritma tidak dapat digunakan untuk identifikasi dan klasifikasi jenis tumor otak

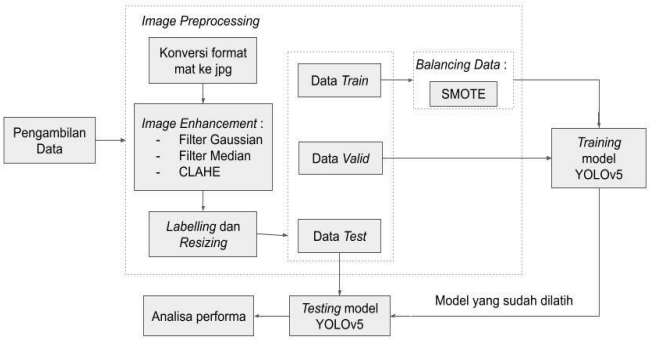
(Brindha et al., 2021). Penelitian lainnya dilakukan oleh Bhanothu et al. untuk mendeteksi tumor otak dan klasifikasi 3 jenis tumor otak, yaitu glioma, meningioma, dan *pituitary tumor dengan Faster* R-CNN dan VGG-19 yang menghasilkan *bounding box* dengan nilai *average precision* glioma (75,18%), meningioma (89,45%), *pituitary tumor* (68,18%) (Bhanothu et al., 2020). Namun terdapat kelemahan dari penelitian ini adalah akurasi yang rendah dalam mendeteksi dan mengklasifikasi jenis tumor otak serta waktu proses komputasi yang cukup lama.

Solusi yang diusulkan terhadap kelemahan-kelemahan pada penelitian-penelitian terkait, yaitu dapat menerapkan metode *image enhancement* untuk perbaikan kualitas citra dan menggunakan model *You Only Look Once* (YOLO) untuk deteksi, klasifikasi, dan lokalisasi objek secara *real-time*, sehingga dapat meningkatkan nilai akurasi dan mempercepat proses komputasi. Berdasarkan penelitian Dzulqarnain et al. yang melakukan klasifikasi kualitas citra buah salak menjadi 4 kelas dengan CNN dan *image enhancement* gaussian blur yang menghasilkan akurasi dari 70,70% menjadi 93,42%. (Dzulqarnain et al., 2019). Selanjutnya, pada penelitian yang menggunakan model *You Only Look Once* (YOLO) untuk deteksi objek yang dilakukan oleh Tan et al. menggunakan model *Faster* R-CNN, *You Only Look Once* (YOLOv3), dan *Single Shot Multibox Detector* (SSD) untuk membandingkan performa kecepatan proses komputasi. Hasil yang diperoleh adalah model YOLO memiliki performa kecepatan komputasi tercepat dibandingkan model lainnya (Tan et al., 2021).

Penggunaan model *deep learning* sudah terbukti baik dalam proses klasifikasi citra tetapi dapat memberikan dampak negatif pada performa *training* model saat dataset yang digunakan mengalami ketidakseimbangan kelas. Ketidakseimbangan kelas terjadi ketika beberapa kelas memiliki jumlah lebih banyak atau sedikit secara signifikan. Data yang tidak seimbang dapat memengaruhi konvergensi selama proses *training model* serta generalisasi model pada proses *testing model*. Hal tersebut dapat memberikan kinerja prediktif yang buruk pada *trained model*, khususnya pada kelas minoritas (Chamseddine et. al., 2022). Masalah tersebut dapat diatasi dengan menggunakan metode *balancing data*. Berdasarkan hasil penelitian Reza, M. dan Ma, J. yang menggunakan beberapa metode *balancing data* pada pengklasifikasian data citra *imbalanced breast cancer* dengan *undersampling*, *oversampling*, SMOTE, dan ADYSN disimpulkan bahwa metode *oversampling* dan SMOTE dapat meningkatkan performa model pada parameter *sensitivity* (*recall*), *specificity*, *F1-Score*, dan akurasi (Reza et.al., 2018).

Berdasarkan dari penelitian-penelitian terkait, maka penelitian ini dilakukan untuk meningkatkan performa model serta menentukan rancangan model deteksi yang terbaik untuk klasifikasi beberapa jenis tumor otak dengan dataset yang tidak seimbang menggunakan metode YOLOv5. Pada penelitian ini menggunakan data citra MRI tumor otak glioma, meningioma, dan *pituitary tumor*. Citra tersebut akan dilakukan tahap *image preprocessing* dengan beberapa metode *image enhancement* untuk perbaikan kualitas citra. Lalu citra akan diberi label atau anotasi berupa *bounding box* pada daerah tumor otak sesuai jenis tumor otak dan data dibagi menjadi data *train,* data *valid*, dan data *test*. Lalu, data *train* akan dilakukan metode *balancing data* untuk menyeimbangkan jumlah data kelas minoritas dengan kelas mayoritas. Tahapan selanjutnya akan dilakukan proses *training* model YOLOv5 pada data *train* dan data *valid* dengan *framework* Google Colaboratory yang akan menghasilkan sebuah *trained model* yang akan digunakan untuk deteksi objek menggunakan data *test*. Lalu, performa *training* dan *testing* model akan dianalisis dengan parameter-parameter evaluasi metrik, seperti presisi, *recall*, *F1-score*, *G-mean*, dan akurasi untuk mengetahui pengaruh metode-metode *image enhancement* dan *balancing data* terhadap kinerja YOLOv5.

2. METODE PENELITIAN



Gambar 1. Blok diagram langkah-langkah penelitian.

2.1 Pengambilan Data

Data yang digunakan dalam penelitian ini merupakan data sekunder citra MRI tumor otak dari *open-access repository figshare* yang dapat diakses melalui *link* berikut: https://figshare.com/articles/dataset/brain_tumor_dataset/1512427/5. Data tersebut diperoleh dari Rumah Sakit Nanfang, Guangzhou, Cina, dan Rumah Sakit Umum, Universitas Kedokteran Tianjing, Cina yang digunakan pada penelitian Cheng et.al. Citra dataset sejumlah 3064 dari 233 pasien yang terdiri dari 708 meningioma, 1426 glioma, dan 930 *pituitary tumor* dengan resolusi gambar 512x512 *pixel* dengan format mat. Berdasarkan sumber asli pemilik dataset, data tersebut telah divalidasi oleh ahli radiologi.

2.2 *Image Preprocessing*

2.2.1 *Image Enhancement*

Metode *image enhancement* berfungsi untuk meningkatkan kualitas citra yang diperoleh supaya memenuhi standar pengolahan yang akan dilakukan menggunakan google colaboratory. Adapun metode-metode *image enhancement* yang digunakan dalam penelitian ini, yaitu *Contrast Limited Adaptive Histogram Equalization Histogram Equalization* (CLAHE) tilegrid 8x8 dan 9x9, filter gaussian sigma 1,2,dan 3, dan filter median sigma 1,2, dan 3. Lalu, metode-metode tersebut dikombinasikan antara CLAHE+filter gaussian dan CLAHE+filter median. Pada kombinasi tersebut, cira hasil CLAHE akan menjadi *input* untuk proses filter gaussian dan filter median secara terpisah.

Filter gaussian digunakan untuk meminimalisir *noise* citra yang dapat menghasilkan citra *blur*. Filter median merupakan proses *filtering* yang digunakan untuk membantu mengurangi noise jenis *salt and pepper* pada citra dan menghaluskan citra. CLAHE digunakan untuk memperbaiki citra dengan meratakan histogram dan meningkatkan kontras citra agar piksel keabuan pada citra relatif sama. Citra hasil dari penerapan metode CLAHE dapat memberikan tampilan citra dengan *noise* yang merupakan efek dari peningkatan kontras pada citra.

2.2.2 *Labeling dan Resizing*

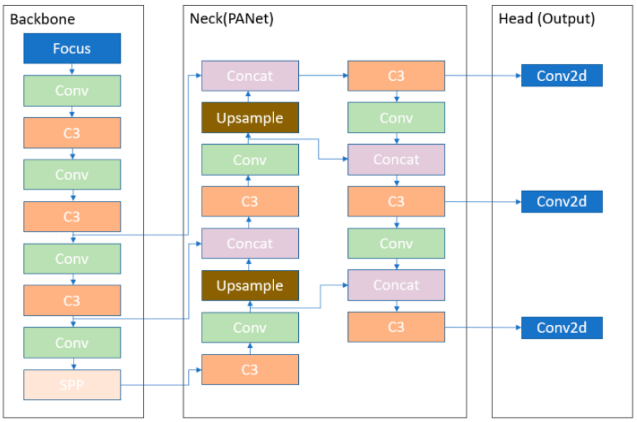
Proses *labeling*/pemberian anotasi menggunakan bantuan layanan Roboflow yang dilakukan dengan memberikan anotasi berupa *bounding box* pada daerah tumor otak citra MRI dengan bantuan koordinat yang diberikan dalam informasi dataset. Hasil dari *labeling* pada penelitian ini adalah 3 kelas, yaitu glioma, meningioma, dan *pituitary tumor*. Setelah diberi anotasi, data dibagi menjadi 70% untuk data *train*, 20% untuk data *valid*, dan 10% untuk data *test*. Selanjutnya proses *resizing* dilakukan untuk menyeragamkan ukuran citra agar model *deep learning* memiliki masukan yang sama dan diharapkan dapat mempercepat dan mempermudah proses komputasi. Dalam penelitian ini dilakukan pada dataset dengan *size* sebesar 512 × 512.

2.2.3 *Balancing Data*

Pada tahap *balancing data* dilakukan untuk menyeimbangkan data train untuk meningkatkan kualitas model yang dilatih. Pada penelitian ini menggunakan salah satu metode *balancing data*, yaitu *Synthetic Minority Oversampling Technique* (SMOTE). SMOTE bekerja tidak hanya menduplikasikan data, tetapi juga menghasilkan hasil duplikasi data dengan nilai yang berbeda dengan mensintesis sampel baru dari kelas minoritas.

2.3 *Training Data*

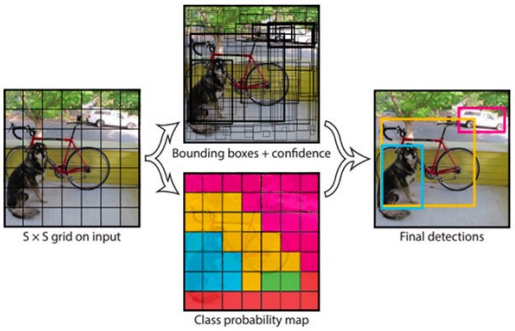
Pada tahap ini objek akan dipelajari oleh salah satu model deteksi objek secara otomatis berbasis *deep learning* yaitu YOLOv5 yang dapat diperoleh dari Github yang di-*clone* pada *framework* google colaboratory. Tahap ini menggunakan data *train* untuk menyesuaikan *weight* pada *network* dan data *valid* digunakan untuk meminimalkan terjadinya *overfitting* yang dapat menyebabkan pendeteksian pada *testing data* tidak akurat. Proses *training data* dilakukan pada layanan Google Colaboratory yang menyediakan GPU dengan kapasitas 12GB dengan *support* NVidia, sehingga proses *training* dapat dilakukan lebih cepat. Pada penelitian ini menggunakan *batch size* = 32 dan *epoch* = 252.



Gambar 2. Arsitektur YOLOv5 (Nepal et al., 2022).

Model YOLOv5 memiliki arsitektur yang terdiri dari *backbone, neck,* dan *head* seperti pada Gambar 2. Pada bagian backbone menggunakan CSPDarknet53 yang merupakan gabungan dari CSPNet dan Darknet yang berfungsi untuk proses ekstraksi fitur objek deteksi dan dapat mempercepat proses komputasi, serta meningkatkan akurasi. Pada bagian *neck* menggunakan jaringan agregasi jalur (PANet) yang berfungsi untuk mengidentifikasi objek dan meningkatkan akurasi lokalisasi objek. Pada bagian *head* dapat yang menghasilkan *bounding box* pada objek deteksi sebagai proses hasil deteksi seperti Gambar 3 (Xu et al., 2021).

Proses deteksi memanfaatkan nilai *threshold* dari *Intersection over Union* (IoU) yang dimana merupakan suatu matrik evaluasi untuk mengukur perbandingan antara area irisan *bounding box* sebenarnya dan *bounding box* prediksi dengan area gabungan *bounding box* sebenarnya dan *bounding box* prediksi. Objek yang dinyatakan berhasil dideteksi memiliki nilai diatas *threshold* IoU. Nilai IoU diatas nilai *threshold* dan memperoleh klasifikasi kelas yang tepat maka prediksi dikategorikan sebagai *True Positive*, sedangkan jika nilai IoU diatas nilai *threshold* dan hasil prediksi salah maka prediksi dikategorikan sebagai *False Positive*, sedangkan nilai IoU di bawah nilai *threshold* maka hasil prediksi digolongkan sebagai *False Negative*. Lalu, hasil dari *training data* akan menghasilkan model terlatih dengan *weight* yang yang terlatih yang akan digunakan untuk proses *testing data* serta hasil deteksi dari proses validasi data.



Gambar 3. Skema proses deteksi objek pada YOLO (Wai et al., 2019).

2.4 *Testing Data*

Pada tahap ini dilakukan untuk menguji kinerja dari model yang sudah dilatih dengan *testing data*. Kinerja model terlatih dapat dikatakan berhasil, jika dapat mendeteksi dan mengklasifikasi daerah tumor berdasarkan jenis tumor otak glioma, meningioma, dan *pituitary tumor*, serta dapat menghasilkan *bounding box* dengan *class probability* dan nilai *confidence* di atas *threshold* IoU.

2.5 Analisis data

2.5.1 Perhitungan Kualitas Citra

Perhitungan Mean Square Error (MSE) dan Peak Signal-to-Noise Ratio (PSNR) dilakukan untuk menganalisis perbaikan kualitas citra secara kuantitatif. Perhitungan MSE dan PSNR dapat dilakukan pada layanan google colaboratory menggunakan kode program python sebagai berikut :

```
mse = np.mean((asli - hasil) ** 2)
psnr = 10 * log10((255**2) / mse)
```

Nilai MSE diperoleh dengan membandingkan nilai selisih pixel-pixel citra asal dengan citra hasil. Nilai 255 pada perhitungan nilai PSNR merupakan nilai maksimal pada pixel. Berdasarkan dari perhitungan PSNR, semakin kecil nilai MSE maka semakin besar nilai PSNR.

2.5.2 Perhitungan Performa Model YOLOv5

Confusion Matrix merupakan sebuah tabel hasil prediksi pada permasalahan klasifikasi digunakan untuk

menunjukkan kinerja model untuk melakukan klasifikasi pada beberapa data uji berdasarkan *bounding box* pada hasil deteksi citra tumor otak. Parameter-parameter *confusion matrix* dapat digunakan untuk mengukur kinerja model adalah seperti berikut :

$$Recall = \frac{TP}{(TP + FN)} \quad (1)$$

$$Presisi = \frac{TP}{(TP + FP)} \quad (2)$$

$$Specificity = \frac{TN}{(TN + FP)} \quad (3)$$

$$Akurasi = \frac{(TP + TN)}{(TP + FP + TN + FN)} \quad (4)$$

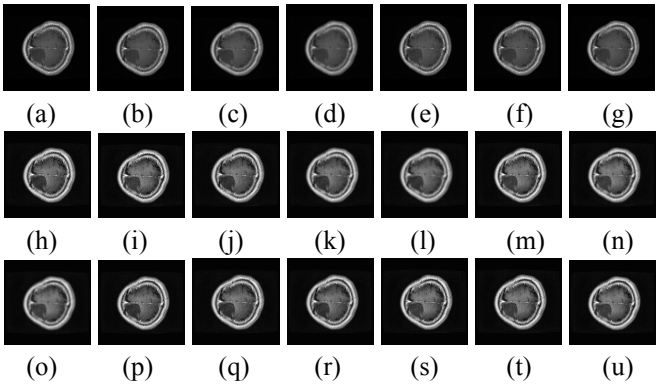
$$F1 - Score = \frac{2 * Recall * Presisi}{Recall + Presisi} \quad (5)$$

$$G - mean = \sqrt{recall \star specificity} \quad (6)$$

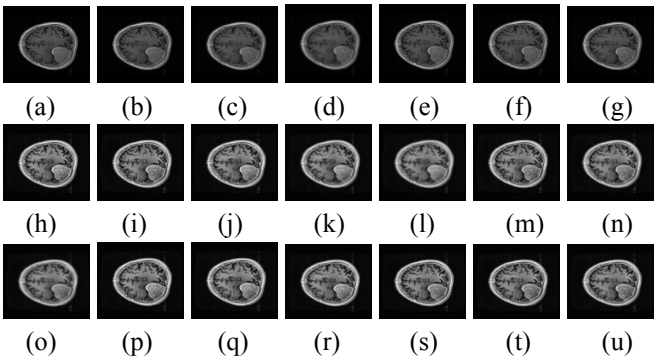
3. HASIL DAN PEMBAHASAN

3.1 Hasil *Image Enhancement*

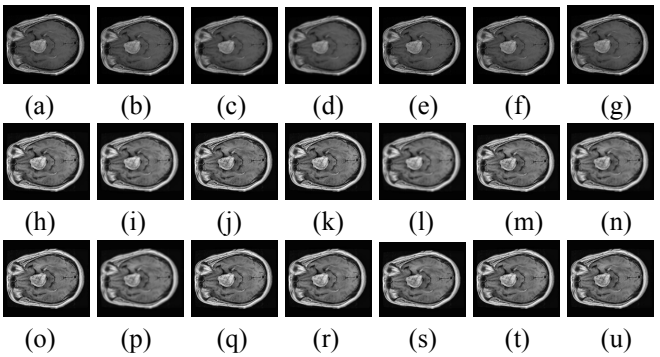
Citra hasil *image enhancement* dapat diamati secara visual. Berdasarkan hasil pengamatan citra glioma (Gambar 3), meningioma (Gambar 4), dan *pituitary tumor* (Gambar 5), semakin besar nilai sigma yang digunakan maka akan menghasilkan citra yang semakin *blur* atau semakin halus. Citra hasil filter median memiliki tampilan yang lebih jelas dan halus dibandingkan dengan citra asli karena penerapan filter median dapat mengurangi *noise* bintik hitam dan putih (*salt and pepper*) pada citra. Citra dengan filter median radius 3 menghasilkan citra yang paling halus dibandingkan dengan citra dengan radius 1 dan radius 2. Pada citra hasil CLAHE memiliki tampilan yang kontras dan lebih terang dibandingkan dengan citra aslinya dan semakin besar *tilegrid* pada CLAHE maka semakin kontras citra, sehingga objek pada citra terlihat lebih jelas. Citra hasil *image enhancement* juga dapat dinilai kualitas hasil perbaikannya secara kualitatif menggunakan *Mean Square Error* (MSE) dan *Peak Signal-to Noise Ratio* (PSNR).



Gambar 3. Hasil *image enhancement* citra glioma (a) Asli (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3



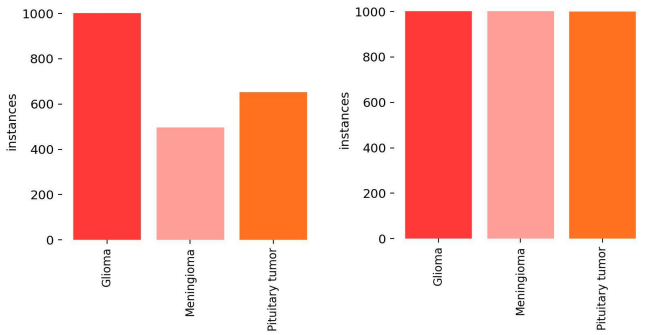
Gambar 4. Hasil *image enhancement* citra meningioma (a) Asli (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3



Gambar 5. Hasil *image enhancement* citra *pituitary tumor* (a) Asli (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3

3.2 Hasil *Balancing Data*

Metode *balancing data* yang digunakan pada penelitian ini adalah *Synthetic Minority Over-sampling Technique* (SMOTE). Kelas yang menerapkan metode *balancing data* adalah kelas meningioma dan *pituitary tumor* yang menjadi kelas minoritas dan kelas glioma menjadi kelas mayoritas karena kelas glioma memiliki jumlah data yang paling banyak yang digambarkan pada Gambar 4(a). Setelah dilakukan proses *balancing data*, Jumlah meningioma dan *pituitary tumor* sama dengan kelas glioma seperti pada Gambar 4(b).

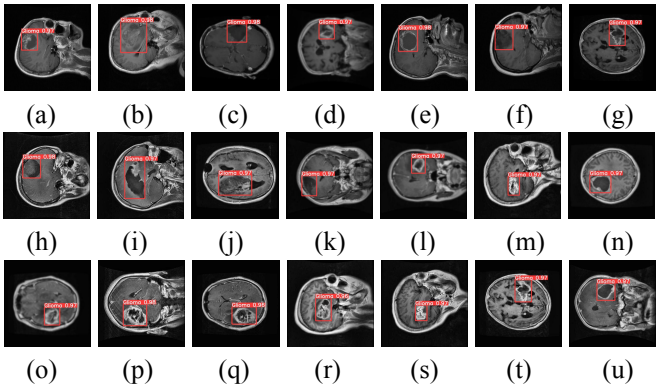


Gambar 6. Grafik data asli dan data hasil *balancing data* (a) Grafik jumlah citra per kelas data asli (b) Grafik jumlah citra per kelas data SMOTE

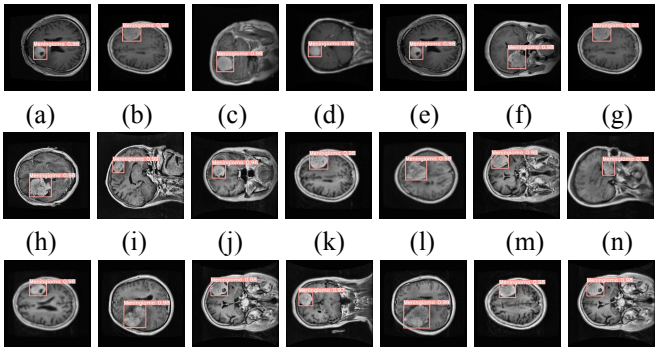
3.3 Hasil Deteksi Citra

Pada citra kelas glioma memiliki hasil deteksi terkecil dibandingkan dengan kelas meningioma dan *pituitary tumor* karena memiliki karakteristik tumor yang intensitasnya lebih gelap (*hypointense*) atau sama (*isointense*) dengan jaringan otak normal, sehingga lebih sulit untuk dideteksi. Sedangkan pada karakteristik tumor meningioma dan *pituitary tumor* lebih terang (*hyperintense*) dari karakteristik jaringan otak normal, sehingga lebih mudah untuk dideteksi oleh model.

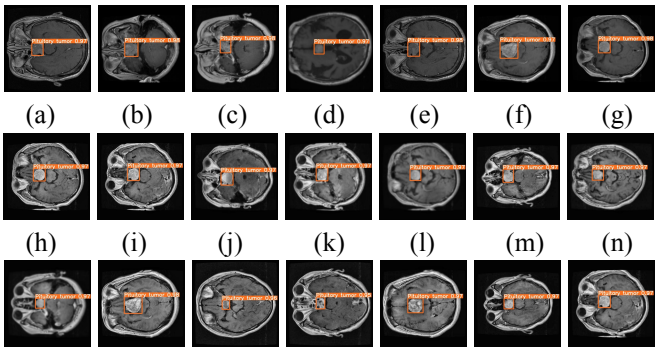
Hasil deteksi pada citra dapat menampilkan *bounding box*, serta nilai *confidence* dan *class probability* dari kelas glioma, meningioma, dan *pituitary tumor* seperti pada Gambar 7, Gambar 8, dan Gambar 9. Parameter-parameter yang dihasilkan dari proses *training data* adalah nilai presisi, *recall*, dan *F1-score*. Parameter-parameter yang dihasilkan dari *testing data* adalah nilai *G-mean* dan akurasi yang dilakukan perhitungan dengan persamaan-persamaan *confusion matrix*.



Gambar 7. Hasil deteksi citra glioma (a) Tanpa *image enhancement* (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3



Gambar 8. Hasil deteksi citra meningioma (a) Tanpa *image enhancement* (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3

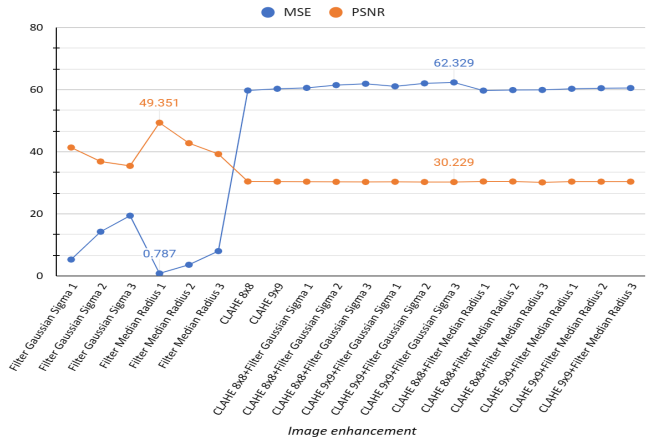


Gambar 9. Hasil deteksi citra *pituitary tumor* (a) Tanpa *image enhancement* (b) Filter gaussian sigma 1 (c) Filter gaussian sigma 2 (d) Filter gaussian sigma 3 (e) Filter median radius 1 (f) Filter median radius 2 (g) Filter median radius 3 (h) CLAHE *tilegrid* 8x8 (i) CLAHE *tilegrid* 9x9 (j) CLAHE 8x8+filter gaussian sigma 1 (k) CLAHE 8x8+filter gaussian sigma 2 (l) CLAHE 8x8+filter gaussian sigma 3 (m) CLAHE 9x9+filter gaussian sigma 1 (n) CLAHE 9x9+filter gaussian sigma 2 (o) CLAHE 9x9+filter gaussian sigma 3 (p) CLAHE 8x8+filter median radius 1 (q) CLAHE 8x8+filter median radius 2 (r) CLAHE 8x8+filter median radius 3 (s) CLAHE 9x9+filter median radius 1 (t) CLAHE 9x9+filter median radius 2 (u) CLAHE 9x9+filter median radius 3

3.4 Analisis Hasil

3.4.1 Analisis Hasil Perbaikan Kualitas Citra

Pada analisis perbaikan kualitas citra dilakukan perhitungan nilai MSE dan PSNR untuk mengetahui variasi metode *image enhancement* yang terbaik dalam memperbaiki kualitas citra MRI tumor otak secara analisis kuantitatif. Nilai MSE diperoleh dari selisih antara data hasil dengan data asli yang dikuadratkan, lalu hasil kuadrat selisih tersebut dirata-ratakan. Pada nilai PSNR diperoleh dari perbandingan antara nilai maksimum sinyal atau *pixel* citra dengan banyaknya *noise* atau nilai MSE pada citra.



Gambar 10. Grafik nilai MSE dan PSNR pada variasi *image enhancement*

Pada Gambar 10 merupakan grafik nilai MSE dan PSNR dari setiap citra variasi metode *image enhancement*. Berdasarkan grafik nilai MSE dan PSNR tersebut, variasi *image enhancement* filter median radius 1 (kernel 3x3) merupakan metode yang paling baik dibandingkan dengan metode lainnya, sedangkan CLAHE 9x9+filter gaussian sigma 3 merupakan metode yang terburuk. Pada metode filter median radius 1 memiliki nilai MSE paling kecil dan nilai PSNR yang paling besar dibandingkan dengan metode lainnya. Nilai MSE yang kecil menandakan kecilnya nilai *error*, sehingga dapat dikatakan bahwa citra filter median radius 1 memiliki jumlah *noise* yang sedikit. Hal tersebut dapat terjadi karena filter median berfungsi untuk mengurangi *noise* bercak hitam dan putih (*salt and pepper*) pada citra. Nilai PSNR yang besar menandakan bahwa tingginya kualitas citra hasil yang berhubungan dengan kecilnya nilai *error* dari nilai MSE.

Pada citra yang diterapkan metode CLAHE, memiliki nilai MSE yang relatif tinggi dan nilai PSNR yang relatif rendah. Hal ini dikarenakan metode CLAHE berfungsi untuk memperbaiki kontras pada citra dan tidak mengurangi *noise* melainkan menambahkan *noise* pada citra. Sehingga, pada variasi metode *image enhancement* dilakukan kombinasi citra CLAHE dengan filter gaussian dan filter median yang bertujuan untuk mengurangi *noise* citra. Kombinasi tersebut tidak memberikan efek yang signifikan tetapi dapat sedikit meningkatkan kualitas citra. Pada citra yang diterapkan metode CLAHE 9x9+filter gaussian sigma 3 memiliki nilai MSE tertinggi dan nilai PSNR terendah. Hal tersebut dapat terjadi karena citra CLAHE 9x9 memiliki kontras yang tinggi serta *noise* diterapkan filter gaussian sigma 3 yang dapat menyebabkan citra *blur*, sehingga dapat menurunkan kualitas citra.

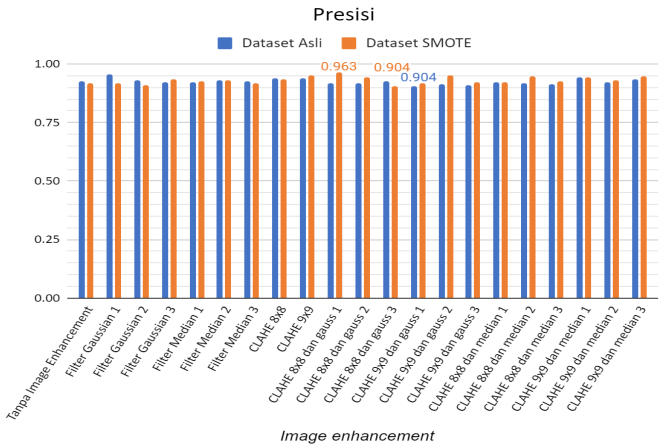
3.4.2 Analisis performa model YOLOv5

Pada analisis hasil dari performa model YOLOv5 pada setiap variasi dataset dan variasi metode *image enhancement*. Variasi dataset yang dimaksud adalah dataset asli dan dataset hasil metode *balancing data*, yaitu dataset SMOTE. Analisis hasil performa model pada penelitian ini menggunakan beberapa parameter matriks evaluasi, yaitu presisi, *recall*, dan *F1-score* untuk mengevaluasi performa model YOLOv5. Analisis hasil yang dilakukan menggunakan grafik hasil performa model YOLOv5 dari proses *training data* untuk mempermudah proses perbandingan.



Gambar 11. Grafik nilai rata-rata *recall* dataset asli dan SMOTE

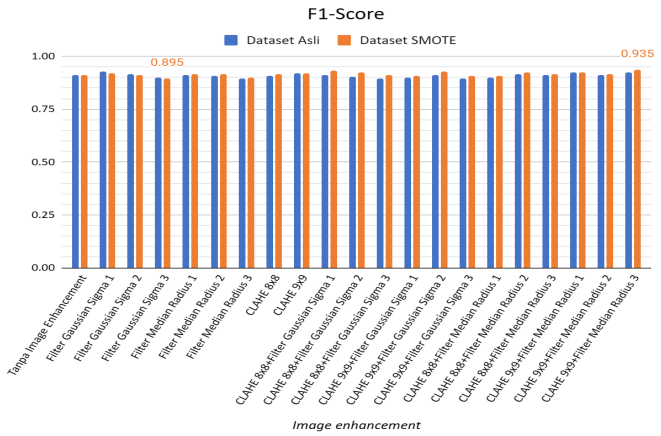
Matriks evaluasi *recall* merupakan matriks evaluasi yang diperoleh dari perbandingan antara jumlah total kelas positif yang dideteksi dengan benar dengan jumlah total kelas positif (*True Positive*). Matriks *recall* digunakan sebagai parameter untuk meminimalkan jumlah *False Negative* atau jumlah objek tumor otak yang tidak terdeteksi**,** sehingga nilai *recall* yang tinggi mengindikasikan banyaknya jumlah objek tumor otak dideteksi. Pada Gambar 11 menunjukkan nilai *recall* tertinggi pada penelitian ini diperoleh dari deteksi objek pada variasi dataset SMOTE citra median CLAHE 9x9+filter median radius 3 dengan nilai sebesar 0.924. Sedangkan nilai *recall* terendah diperoleh dari dataset SMOTE citra filter gaussian sigma 3 dengan nilai sebesar 0.859. Hal tersebut dapat terjadi karena pada citra filter gaussian sigma 3 memiliki karakteristik citra yang sangat halus (*blur*) sehingga objek tumor sulit untuk dideteksi. Sedangkan citra CLAHE 9x9+filter median radius 3 memiliki karakteristik citra yang terang dan jelas sehingga objek tumor mudah dideteksi. Nilai rata-rata *recall* dataset asli dan SMOTE dari seluruh variasi *image enhancement* adalah 0,894 dan 0,9. Nilai rata-rata *recall* meningkat pada dataset SMOTE yang menandakan bahwa model memiliki performa yang lebih baik dalam mendeteksi objek tumor otak pada data yang seimbang.



Gambar 12. Grafik nilai rata-rata presisi dataset asli dan SMOTE

Matriks evaluasi presisi diperoleh dari perbandingan jumlah prediksi benar yang bernilai positif (*True positive*)

dengan jumlah yang diprediksi benar**.** Matriks presisi digunakan sebagai parameter untuk meminimalkan jumlah *False Positive* atau kesalahan deteksi pada objek tumor otak**.** Nilai presisi yang tinggi menunjukkan kelas yang diprediksi positif memang positif dan memiliki proses klasifikasi yang baik, seperti mendeteksi tumor glioma pada citra glioma begitu juga pada pendeteksian tumor meningioma dan *pituitary tumor* dari keseluruhan data citra. Nilai presisi yang tinggi pada suatu model menandakan bahwa model tersebut dapat melakukan proses klasifikasi yang baik. Pada grafik Gambar 12 menampilkan nilai rata-rata presisi tertinggi diperoleh pada dataset SMOTE citra CLAHE 8x8+filter gaussian sigma 1 dengan nilai sebesar 0.963. Sedangkan nilai presisi terendah diperoleh dari dataset SMOTE citra CLAHE 8x8+Filter Gaussian Sigma 3 dan dataset asli citra CLAHE 9x9+filter gaussian sigma 1 dengan nilai yang sama sebesar 0.904. Nilai rata-rata presisi dataset asli dan SMOTE dari seluruh variasi *image enhancement* senilai 0,925 dan 0,931 secara berturut-turut. Nilai rata-rata presisi dataset SMOTE lebih baik dibandingkan dataset asli. Hal tersebut dapat membuktikan bahwa model YOLOv5 memiliki performa yang lebih baik dalam klasifikasi objek dan terjadi kesalahan deteksi objek yang lebih kecil pada data yang seimbang.



Gambar 13. Grafik nilai rata-rata *F1-score* dataset asli dan SMOTE

Pada nilai *recall* dan nilai presisi memiliki hubungan yang timbal balik. Jika nilai *recall* tinggi maka nilai presisi rendah, sebaliknya nilai *recall* rendah maka nilai presisi tinggi. Matriks evaluasi *F1-Score* dapat digunakan untuk mengukur keseimbangan antara *recall* dan presisi. Semakin tinggi nilai *F1-Score* pada suatu model, maka semakin baik nilai presisi dan *recall* yang diperoleh dari model tersebut. Nilai *F1-Score* yang tinggi juga dapat memberikan nilai akurasi yang tinggi pada kelas positif. Nilai rata-rata *F1-score* yang diperoleh dari dataset asli dan SMOTE pada seluruh variasi *image enhancement* adalah 0,909 dan 0,915. Nilai yang diperoleh dataset SMOTE sedikit lebih tinggi dibandingkan dataset asli, menandakan bahwa performa model YOLOv5 lebih baik pada data yang seimbang. Nilai *F1-score* tertinggi pada penelitian ini diperoleh dari dataset SMOTE citra CLAHE 9x9+filter median radius 3 dengan nilai sebesar 0.935. Sedangkan nilai *F1-score* terendah diperoleh pada dataset SMOTE citra gaussian filter gaussian sigma 3 dengan nilai sebesar 0.895 seperti pada Gambar 13.

Matriks evaluasi *G-mean* digunakan untuk mengukur keseimbangan performa klasifikasi pada kelas mayoritas dan minoritas. Semakin tinggi nilai *G-mean*, maka seimbang kualitas performa klasifikasi sebuah model pada kelas minoritas dan mayoritas. Nilai *G-mean* dataset asli dan SMOTE berturut-turut diperoleh sebesar 0,953 dan 0,956. Berdasarkan perbandingan nilai *G-mean*, dataset SMOTE memiliki nilai *G-mean* yang lebih tinggi daripada dataset asli. Hal tersebut dapat dinyatakan bahwa kualitas performa model YOLOv5 untuk mendeteksi dan klasifikasi citra MRI objek tumor kelas glioma, meningioma, dan *pituitary tumor* meningkat pada data yang seimbang.

Pada dataset asli, hasil deteksi memperoleh rata-rata nilai akurasi sebesar 0,917. Pada dataset SMOTE menghasilkan rata-rata nilai akurasi 0,963. Dari hasil tersebut dapat dinyatakan bahwa penerapan *image enhancement* dan teknik *oversampling* pada metode *balancing data* dapat meningkatkan nilai akurasi deteksi dan klasifikasi objek pada citra karena citra hasil *image enhancement* dapat memiliki karakteristik yang lebih kontras dan *noise* citra yang lebih sedikit serta dataset seimbang sehingga objek yang akan dideteksi menjadi lebih jelas dan karakteristik pada dataset dapat dipelajari secara efektif. Hal ini sesuai dengan penelitian yang dilakukan oleh Dzulqarnain et al., (2019) dan Reza et.al., (2018). Rata-rata waktu *testing* dari *testing data* pada data uji semua dataset diperoleh sebesar 6.6 ms. Model rancangan YOLOv5 yang memiliki performa terbaik dari penelitian ini adalah variasi *image enhancement* citra CLAHE 9x9+filter median radius 3 yang menghasilkan nilai akurasi 0,964 dengan waktu *testing* 6,5 ms per citra. Berdasarkan waktu dan akurasi yang diperoleh dari proses *testing data* dapat disimpulkan bahwa model YOLOv5 dapat diterapkan dalam proses deteksi dan klasifikasi yang akurat dan *real time*.

Performa dari suatu model deteksi dan klasifikasi dapat dipengaruhi oleh beberapa faktor, yaitu ukuran objek pada gambar, ukuran resolusi gambar, keseimbangan dataset, dan *backbone* yang digunakan sebagai ekstraksi fitur. Semakin besar ukuran objek pada gambar, maka model akan lebih mudah mendeteksi objek dan memperoleh performa yang lebih baik. Sama dengan ukuran resolusi citra, semakin besar resolusi citra maka akan semakin meningkat model untuk mendeteksi. Namun, jika ukuran resolusi citra terlalu besar dapat memperlambat waktu komputasi pembelajaran model. *Backbone* yang digunakan model YOLOv5 adalah CSPDarckent yang memiliki kelebihan dapat mengurangi waktu komputasi dan meningkatkan kecepatan akurasi. Keseimbangan dataset juga sangat berpengaruh pada kualitas performa model. Jika dataset yang digunakan tidak seimbang, maka performa model yang dihasilkan akan kurang efektif karena kurangnya pembelajaran karakteristik pada kelas minoritas.

4. KESIMPULAN

Berdasarkan hasil penelitian ini dapat disimpulkan bahwa:

1. Penerapan metode *image enhancement* dan *balancing data* dapat meningkatkan akurasi dan performa model YOLOv5 dalam mendeteksi tumor glioma, meningioma, dan *pituitary tumor*.
2. Nilai rata-rata akurasi model YOLOv5 yang dirancang untuk mendeteksi tumor otak glioma, meningioma, dan *pituitary tumor* dari citra MRI dihasilkan sebesar 0,917 dan 0,963 pada dataset asli dan SMOTE dengan rancangan terbaik diperoleh dari CLAHE 9x9+filter median radius 3 pada dataset SMOTE dengan nilai rata-rata *F1-score* sebesar 0,935 dan akurasi 0,964.

5. REFERENSI

Bhanothu , Y., et.al. (2020). Detection and Classification of Brain Tumor in MRI Images using Deep Convolutional Network. International Conference on Advanced Computing and Communication Systems (ICACCS), 248-252. 10.1109/ICACCS48705.2020.9074375

Brindha, P. Gokila., et.al. (2021). Brain tumor detection from MRI images using deep learning techniques. IOP Conference Series : Materials Science and Engineering, 1055, 1 - 7. doi:10.1088/1757-899X/1055/1/012115

Chamseddine , E., et.al. (2022). Handling class imbalance in COVID-19 chest X-ray images classification: Using SMOTE and weighted loss. Applied Soft Computing, 129, 1-14. https://doi.org/10.1016/j.asoc.2022.109588

Chin, S. (2020). Epidemiology of Functioning Pituitary Adenomas. Endocrinology and Metabolism, 35(2), 237 - 242. https://doi.org/10.3803/EnM.2020.35.2.237

Dzulqarnain, M., Suprapto & Makhrus, F. (2019). Improvement of Convolutional Neural Network Accuracy on Salak Classification Based Quality on Digital Image. Indonesian Journal of Computing and Cybernetics Systems, 1(2), 189 - 198. DOI: 10.22146/ijccs.42036

Ghozali, M. & Sumarti, H. (2021). Pengobatan Klinis Tumor Otak pada Orang Dewasa. Jurnal Phi: Jurnal Pendidikan Fisika dan Fisika Terapan, 2(1), 1 - 14

GLOBOCAN. (2020, November 29). Brain, central nervous system. Global Cancer Observatory. https://gco.iarc.fr/today/fact-sheets-cancers

Li, Q., Gao, Z., Wang, Q., Xia, J., Zhang, H., Zhang, H., ... Li, S. (2018). Glioma Segmentation with a Unified Algorithm in Multimodal MRI Images. IEEE Access, 6, 9543–9553. https://doi.org/10.1109/ACCESS.2018.2807698

Maulida, N., Susanto , E. & Murniati, E. (2019). PROSEDUR PEMERIKSAAN MAGNETIC RESONANCE IMAGING (MRI) BRAIN PERFUSI DENGAN METODE ARTERIAL SPIN LABELING (ASL) PADA PASIEN TUMOR. RI (Jurnal Radiografer Indonesia), 2(1), 48 - 58. https://doi.org/10.55451/jri.v2i1.33

Moreau, Jeremy T.., Hankinson, Todd C.., Baillet, S. & Dudley, Roy W. R.. (2020). Individual-patient prediction of meningioma malignancy and survival using the Surveillance, Epidemiology, and End Results database. NPJ Digital Medicine, 3(1), 1 - 10. https://doi.org/10.1038/s41746-020-0219-5

Nepal, U., Eslamiat, H. (2022). Comparing YOLOv3, YOLOv4 and YOLOv5 for Autonomous Landing Spot Detection in Faulty UAVs. Sensors, 22(464), 1 - 15. https://doi.org/10.3390/s22020464

Reza, M. & Ma, J. (2018). Imbalanced Histopathological Breast Cancer Image Classification with Convolutional Neural Network. International Conference on Signal Processing (ICSP 2018), , 619-624. DOI:10.1109/ICSP.2018.8652304

Tan, L., Wu, L. & Chen, W. (2021). Comparison of YOLO v3, Faster R-CNN, and SSD for Real-Time Pill Identification, PREPRINT (Version 1) available at Research Square. https://doi.org/10.21203/rs.3.rs-668895/v1

Wahyuhadi, J., Pratama, M., Wathoni, R. & Basuki, H. (2021). The Indonesian Central Nervous System Tumors Registry (Ina-CTR) : 7 years result from single institution of primary brain tumor epidemiology. Indonesian Journal of Neurosurgery, 4(1), 25 - 35

Wai, Y., Yussof, Z. & Salim, S. (2019). A scalable FPGA based accelerator for Tiny-YOLO-v2 using OpenCL. International Journal of Reconfigurable and Embedded Systems (IJRES). 8. 206. 10.11591/ijres.v8.i3.pp206-214.

Xu, R., Lin, H., Lu, K., Cao,L., Liu, Y. (2021). A Forest Fire Detection System Based on Ensemble Learning. Forests, 12(217), 1 - 17. https://doi.org/10.3390/f12020217